

PROPOSAL

FACE RECOGNITION PADA SISTEM ABSENSI KARYAWAN MENGUNAKAN DEEP LEARNING



RESEARCH

FADHILLAH MOULITA ANDIANI

2001848032

Program Pascasarjana

PROGRAM STUDI TEKNIK INFORMATIKA JENJANG S2

**UNIVERSITAS BINA NUSANTARA
JAKARTA**

2019

PROPOSAL

FACE RECOGNITION PADA SISTEM ABSENSI KARYAWAN MENGUNAKAN DEEP LEARNING



RESEARCH

FADHILLAH MOULITA ANDIANI

2001848032

Pembimbing :

Benfano Soewito, PhD
Tanggal : 02 – 05 – 2019

DAFTAR ISI

Halaman Judul.....	i
Persetujuan Pembimbing.....	ii
DAFTAR ISI.....	iii
DAFTAR GAMBAR	iv
DAFTAR TABEL	v
BAB 1 PENDAHULUAN	6
1.1 Latar Belakang	6
1.2 Rumusan Masalah	10
1.3 Tujuan dan Manfaat	10
1.4 Ruang Lingkup.....	11
BAB II LANDASAN TEORI	12
2.1 Otentikasi Biometrik	12
2.2 <i>Deep Learning</i>	13
2.3 <i>Convolutional Neural Network (CNN)</i>	14
2.4 <i>Face Recognition</i>	17
2.6 <i>Transfer Learning</i>	22
2.6.1 Triplet Loss	22
2.7 Support Vector Machine (SVM) Classifier.....	24
2.8 <i>Raspberry Pi</i>	26
2.8.1 <i>Raspberry Pi 3</i>	27
2.9 Tinjauan Pustaka	28
BAB III METODOLOGI.....	31
3.1 Kerangka Pikir	31
3.2 Perancangan Sistem	34
3.3 Pengambilan Data	37
3.4 Analisis Data	40
DAFTAR PUSTAKA	43

DAFTAR GAMBAR

Gambar 1.1 <i>Face Recognition</i> pada model DCNN.....	9
Gambar 2.1 Karakter Fisik dan Perilaku pada Biometrik	13
Gambar 2.2 Proses konvolusi pada CNN.....	15
Gambar 2.3 Contoh arsitektur pada CNN	16
Gambar 2.4 Face Recognition.....	17
Gambar 2.5 Proses Pengenalan Wajah.....	18
Gambar 2.6 Peta Fitur dari Convolutional Neural Network	20
Gambar 2.7 Arsitektur MTCNN	20
Gambar 2.8 Tahapan P-Net pada MTCNN.....	21
Gambar 2.9 Tahapan R-Net pada MTCNN	21
Gambar 2.10 Tahapan O-Net pada MTCNN	21
Gambar 2.11 Alur Proses Transfer Learning	22
Gambar 2.12 Triplet Loss	23
Gambar 2.13 Hyperplane pada SVM.....	24
Gambar 2.14 Hyperplane pada 2D dan 3D	25
Gambar 2.15 Raspberry Pi 3	27
Gambar 3.1 Kerangka Pikir.....	33
Gambar 3.2 Ilustrasi Sistem.....	34
Gambar 3.3 Perancangan Sistem <i>Face Recognition</i>	35

DAFTAR TABEL

Tabel 2.1 Ringkasan Tinjauan Pustaka	28
Tabel 3.1 Pengambilan Data.....	38
Tabel 3.2 Jadwal Penelitian.....	42

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Suatu perusahaan tidak akan berjalan sebagaimana mestinya jika tidak mempunyai karyawan yang memadai untuk menjalani proses bisnis perusahaan. Untuk menghargai pekerjaan para karyawan pada suatu perusahaan, tentunya perusahaan mempunyai penghargaan tertentu seperti memberikan kenaikan gaji, ataupun bonus tahunan. Penghargaan tersebut dapat diberikan dengan mengukur performa karyawan dalam bekerja, salah satu faktor pengukurnya dinilai dari seberapa banyak kehadiran karyawan yang tepat waktu, keterlambatan, ijin dan juga ketidakhadiran. Pencatatan kehadiran secara manual harus dilakukan setiap hari selama jam kerja, dan menjadi tidak efektif untuk diterapkan karna akan memakan waktu lama untuk menghitung rata-rata kehadiran dari karyawan tersebut. Selain dapat memakan waktu lama dalam pencatatan kehadiran karyawan, karyawan juga sulit untuk melihat jumlah absensi, dan sisa cuti mereka.

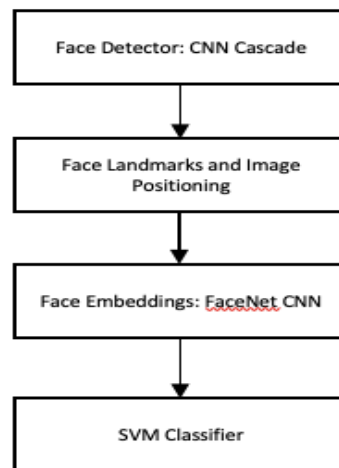
Untuk memperoleh hasil pencatatan kehadiran yang akurat, saat ini banyak digunakan beberapa metode untuk pencatatan absensi, seperti menggunakan mesin absensi yang telah banyak beredar. Mesin absensi ini menggunakan metode yang berbeda-beda pula dalam mengidentifikasi orang. Masing-masing metode identifikasi ini memiliki kekurangan dan kelebihanannya sendiri. Jika ingin menggunakan mesin absensi, maka perusahaan harus mengeluarkan biaya untuk membeli mesin absensi tersebut, dan juga terdapat infrastruktur yang harus dibeli dan dipasang ketika perusahaan hendak menerapkan sistem ini. Selain itu jumlah

karyawan yang akan menggunakan mesin absensi juga harus sebanding dengan jumlah mesin absensi itu sendiri, kalau tidak sebanding akan berdampak adanya antrian ketika secara bersamaan karyawan hendak mengakses mesin absensi tersebut, misalnya ketika jam masuk dan jam pulang kantor.

Mesin absensi menggunakan metode yang berbeda-beda untuk mengidentifikasi, salah satunya dengan metode *biometric*. Saat ini, penggunaan *biometric recognition* merupakan cara yang umum dan dapat diandalkan untuk mengotentikasi identitas seseorang yang hidup berdasarkan karakteristik fisiologis ataupun perilaku. Karakteristik fisiologis adalah suatu karakteristik fisik yang relatif stabil, seperti sidik jari, pola iris, wajah, dan siluet tangan. Pengukuran seperti ini pada dasarnya tidak berubah dan tidak dapat diubah tanpa paksaan yang signifikan, sehingga dapat mengurangi kecurangan yang dilakukan oleh karyawan dalam melakukan absensi. Kadry et al (Kadry et al., 2013) menerapkan *attendance wireless system* menggunakan *iris recognition*, sistem ini memindai mata menggunakan sensor dan algoritma Daugman untuk *iris recognition*. Pada penerapan metode ini, didapatkan beberapa kekurangan yaitu *iris recognition* sulit dilakukan pada jarak yang jauh dikarenakan ukurannya yang kecil, *iris recognition* rentan terhadap kualitas gambar yang tidak memadai, dan penderita diabetes serta beberapa penyakit lain menyebabkan terjadinya perubahan pada iris mata sehingga sulit untuk melakukan *scanning* iris. Rao dan Satoa (Rao, 2012) mengembangkan sistem absensi otomatis menggunakan teknik verifikasi *fingerprint* yang dilakukan dengan ekstraksi teknik *minutiae*. Penelitian ini dilakukan dengan menggunakan pendekatan kuantitatif dengan merancang kuesioner sebagai instrument pengumpulan data berdasarkan teknologi *biometric* pencocokan sidik jari.

Pada metode biometrik *fingerprint* ini juga terdapat celah kecurangan untuk pendataan absensi, yaitu dapat dimanipulasi menggunakan jari buatan, *fingerprint scanner* melakukan *scanning* pada satu bagian dari jari seseorang, sehingga rentan terhadap kesalahan, dan *fingerprint* dapat tertinggal pada berbagai tempat sehingga ada kemungkinan dapat dicuri.

Dengan adanya kelemahan-kelemahan metode *recognition* tersebut, penggunaan *face recognition* dapat menjadi suatu solusi praktis, lebih flexible, dan dapat mengurangi *human errors* pada pengidentifikasi manusia. Teknologi *face recognition* adalah cabang penting dari *biometrics* dan juga merupakan focus studi *pattern recognition* dan *computer vision*, yang mana dapat diterapkan oleh berbagai aplikasi potensial untuk sistem yang mampu mengenali wajah, seperti pengawasan, identifikasi pribadi, kontrol akses, dan konferensi (Lang 2008). Proses dari *face recognition* itu sendiri dapat dibagi menjadi beberapa langkah, langkah yang paling penting adalah *face detection* dan *face recognition*. Sistem absensi menggunakan *face recognition* ini sudah banyak diterapkan dengan berbagai macam metode, salah satunya menggunakan *deep learning*. Kemajuan yang sangat pesat dalam metode *deep learning* membuat tingkat akurasi terhadap pengenalan wajah semakin tinggi dengan menggunakan *deep CNN (Convolutional Neural Network)*. Schroff et al (Schroff et al., 2015) mempresentasikan sistem revolusioner – *FaceNet* yang bergantung pada *Deep Neural Network (DNN)* untuk melakukan pengenalan wajah.



Gambar 1.1 Face recognition model pada metode DCNN

Model yang diusulkan mempunyai beberapa langkah penting: *face detection*, *image preprocessing* – menemukan *face landmarks* dan *face positioning*, serta melakukan *generate face embeddings* dan *classification*. Metode ini mencapai hasil yang menakjubkan pada dataset Labeled Faces in the Wild (LFW), yaitu mencapai 99,63%. Penggunaan *Deep Convolutional Neural Network* (DCNN) pada pengenalan wajah dapat diterapkan untuk identifikasi data karyawan sebagai data absensi. Namun, pengujian yang dilakukan menggunakan model ini memberikan kegagalan pada saat pencahayaan pada wajah terlalu terang dan hanya di uji cobakan pada satu karyawan secara berulang.

Untuk memperbaiki model sebelumnya, pengujian ini akan menerapkan proses *face recognition* sebagai berikut: proses *face detection* yang akan diterapkan menggunakan MTCNN (*Multi-task Convolutional Neural Network*) *cascade* untuk mendeteksi wajah dan menemukan *face landmarks*, kemudian melakukan *embeddings* menggunakan *FaceNet* (proses *pre-trained*) untuk mengatasi permasalahan pencahayaan yang terlalu terang pada wajah, selanjutnya akan diterapkan SVM (*Support Vector Machine*) untuk klasifikasi wajah.

Model tersebut akan diuji cobakan melalui langkah berikut: mengambil gambar wajah karyawan terlebih dahulu untuk dimasukkan ke dalam *database* karyawan, sensor akan diletakkan diatas pintu yang mana karyawan akan melewati sensor tersebut, sensor menggunakan kamera *Rapsberry Pi V2* dan akan diproses menggunakan *Rapsberry Pi 3 B+*, selanjutnya hasil dari *face recognition* akan dicocokkan dengan *database* wajah karyawan untuk mencatat absensi.

1.2 Rumusan Masalah

Rumusan masalah pada studi kasus ini akan diuraikan melalui pertanyaan berikut:

1. Bagaimana merancang sebuah sistem absensi yang mampu mengatasi beberapa keterbatasan yang terjadi pada sistem absensi biometrik lainnya dengan menerapkan *deep neural network* (DNN) untuk *face recognition*
2. Apakah melakukan *pre-trained* pada model akan memberikan deteksi yang benar dan tingkat akurasi yang tinggi ketika pencahayaan wajah terlalu terang
3. Apakah penerapan *multi-task convolutional neural network* memberikan hasil yang akurat untuk mendeteksi banyak wajah, dan apakah dapat mengatasi permasalahan penggunaan kacamata pada wajah

1.3 Tujuan dan Manfaat

Tujuan dari penelitian ini adalah :

1. Menerapkan metode *deep neural network* (DNN) pada sistem absensi karyawan untuk mendeteksi wajah

2. Melakukan proses *pre-trained* menggunakan *FaceNet* model agar dapat mengenali wajah yang disoroti cahaya terlalu terang
3. Melakukan penerapan *multi-task convolutional neural network* untuk mendeteksi banyak wajah ketika karyawan masuk secara bersamaan melalui pintu yang sama

Manfaat penelitian :

1. Terciptanya sistem absensi dengan *face recognition* yang lebih aman dan dapat mengatasi kekurangan-kekurangan dari sistem absensi metode biometrik lainnya
2. Mendapatkan tingkat akurasi yang lebih baik pada pendeteksian wajah dan mengurangi hambatan-hambatan dalam mendeteksi wajah ketika menerapkan proses *multi-task convolutional neural network* dan *pre-trained FaceNet* model

1.4 Ruang Lingkup

Ruang lingkup dalam studi kasus ini, yaitu:

1. Pengujian akan dilakukan dengan menerapkan *deep neural network* pada satu sensor untuk mendeteksi wajah, *framework* yang akan digunakan untuk proses *deep learning* ini adalah *tenserflow*. *Face detection* yang akan digunakan adalah *Multi-task convolutional neural network*, kemudian hasilnya akan di *embeddings* dengan melakukan *pre-trained* proses pada model *FaceNet* menggunakan *LFW dataset* dan algoritma *SVM classifier* digunakan untuk menklasifikasikan hasil *encoding* wajah. Hasilnya akan digunakan untuk memasukkan data absensi pada sistem absensi karyawan

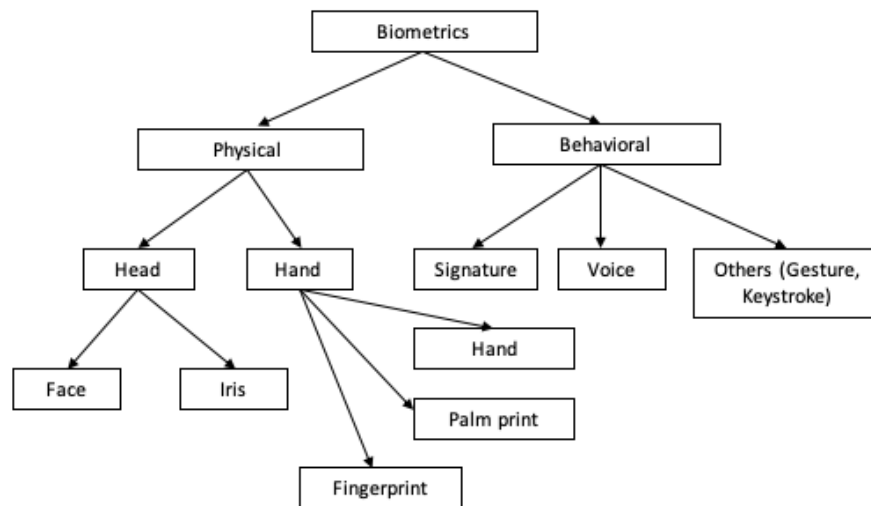
BAB II LANDASAN TEORI

Untuk mendukung pengujian ini, maka perlu dikemukakan hal-hal atau teori-teori yang berkaitan dengan permasalahan dan ruang lingkup pembahasan sebagai landasan dalam pembuatan pengujian ini.

2.1 Otentikasi Biometrik

Proses identifikasi dan otentikasi merupakan kemampuan untuk memverifikasi dan mengkonfirmasi suatu identitas. Proses ini diselesaikan dengan menggunakan satu atau satuan kombinasi dari tiga teknik identifikasi tradisional: sesuatu yang anda miliki; sesuatu yang anda ketahui; atau sesuatu yang merupakan anda (J.Ashbourn, 2000). Otentikasi biometrik dikenal sebagai identifikasi otomatis, atau verifikasi identitas, dari suatu individu menggunakan suatu fitur biological yang memiliki *physiological* karakteristik seperti sebuah sidik jari, geometri tangan, scan retina, scan iris dan pengenalan wajah atau sesuatu yang dilakukan yang memiliki karakteristik perilaku, seperti sebuah tanda tangan (J.L. Wayman & Alyea L., 2000).

Menurut Woodward (J.D. Woodward, 2001) umumnya, karakteristik fisik dan perilaku yang digunakan oleh *biometrics* termasuk kedalam taxonomy berikut ini :



Gambar 2.1 Karakter Fisik dan Perilaku pada Biometrik

2.2 Deep Learning

Deep learning merupakan bagian dari metode pembelajaran sistem yang direpresentasikan oleh fakta. *Deep Learning* merupakan salah satu cabang *machine learning* (ML) yang menggunakan *Deep Neural Network* untuk menyelesaikan permasalahan pada domain ML. Pengetahuan yang diperolehnya merupakan pengetahuan yang *supervised*, *semi-supervised* dan *unsupervised* (Alahi et al., 2016). *Deep* mengenal suatu gaya dengan melakukan pemrosesan fakta dan gaya komunikasi dalam mesin biologis yang mengerjakan, termasuk pengkodean saraf yang mencoba untuk menguraikan berbagai rangsangan dan respon dari syaraf terkait di dalam fikiran (Badarinarayan, 2015). Algoritma pada *deep learning* memiliki fitur yang unik yaitu sebuah fitur yang mampu mengekstraksi secara otomatis. Hal ini berarti algoritma yang dimilikinya secara otomatis dapat menangkap fitur yang relevan sebagai keperluan dalam pemecahan suatu masalah. Algoritma semacam ini sangat penting dalam sebuah kecerdasan buatan karena mampu mengurangi beban pemrograman dalam memilih fitur yang eksplisit.


Algoritma ini akan menjadi semakin kompleks dan bersifat abstrak ketika jumlah lapisan tersembunyi (*hidden layer*) semakin bertambah banyak. Jaringan saraf yang dimiliki oleh *deep learning* terbentuk dari hirarki sederhana dengan beberapa lapisan hingga tingkat tinggi atau banyak lapisan (*multi layer*). Berdasarkan hal itulah *deep learning* dapat digunakan untuk memecahkan masalah kompleks yang lebih rumit dan terdiri dari sejumlah besar lapisan transformasi non-linier. Berikut jenis *deep learning*:

- *Unsupervised learning*: tipe ini digunakan pada saat label dari variable target tidak tersedia dan korelasi nilai yang lebih tinggi harus dihitung dari unit yang diamati untuk menganalisis polanya.
- *Hybrid deep networks*: pendekatan tipe ini bertujuan agar dapat dicapai hasil yang baik dengan menggunakan pembelajaran yang diawasi untuk melakukan analisis pola atau dapat juga dengan menggunakan pembelajaran tanpa pengawasan.

2.3 Convolutional Neural Network (CNN)

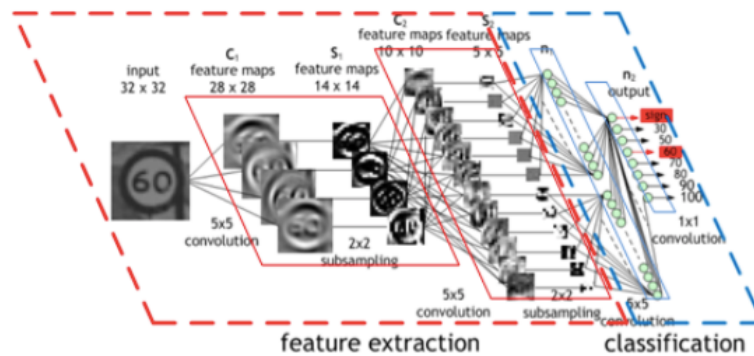
Convolutional Neural Network adalah salah satu metode *machine learning* dari pengembangan *Multi Layer Perceptron* (MLP) yang didesain untuk mengolah data dua dimensi. CNN termasuk dalam jenis *Deep Neural Network* karena dalamnya tingkat jaringan dan banyak diimplementasikan dalam data citra. CNN memiliki dua metode; yakni klasifikasi menggunakan *feedforward* dan tahap pembelajaran menggunakan *backpropagation*. Cara kerja CNN memiliki kesamaan pada MLP, namun dalam CNN setiap neuron dipresentasikan dalam bentuk dua dimensi, tidak seperti MLP yang setiap neuron hanya berukuran satu dimensi.

Operasi linear pada CNN menggunakan operasi konvolusi, dengan bobot yang tidak lagi satu dimensi saja, namun berbentuk empat dimensi yang merupakan kumpulan kernel konvolusi seperti pada Gambar.2. Dimensi bobot pada CNN adalah: *neuron input x neuron output x tinggi x lebar*



Gambar 2.2 Proses konvolusi pada CNN

CNN merupakan pengembangan lebih lanjut dari MLP karena menggunakan metode yang mirip dengan dimensi yang lebih banyak. Di algoritma CNN ini, input dari *layer* sebelumnya bukan *array* 1 dimensi melainkan *array* 2 dimensi. Jika di analogikan dengan fitur dari wajah manusia, *layer* pertama merupakan refleksi goresan-goresan berbeda arah, pada *layer* kedua fitur seperti bentuk mata, hidung, dan mulut mulai terlihat, hal ini karena di lakukan *pooling*/penggabungan dari *layer* pertama yang masih berupa goresan-goresan, pada *layer* ketiga akan terbentuk kombinasi fitur-fitur mata, hidung, dan mulut yang nantinya akan disimpulkan dengan wajah orang tertentu.




Gambar 2.3 Contoh arsitektur pada CNN

Sama halnya dengan *Neural Network* pada umumnya, CNN memiliki beberapa lapisan tersembunyi (*hidden layers*) dari sebuah input berupa vektor tunggal. Pada gambar 2.3, dengan input berupa citra yang dijadikan vektor tunggal 32×32 . Di tiap *hidden layer*, terdapat beberapa neuron layaknya empat feature maps C_1 pada gambar tersebut. *Neuron-neuron* pada C_1 dihubungkan dengan neuron di S_1 , dan seterusnya. Lapisan terakhir yang terhubung dengan lapisan-lapisan tersembunyi sebelumnya disebut dengan *output layer* dan merepresentasikan hasil akhir klasifikasi kelas. Seperti n_2 yang ditunjukkan oleh Gambar 2.2 yang merepresentasikan hasil pada *output layer*, seperti 30, 50, 60, dll. Keseluruhan skala dalam objek sangat penting agar input tidak kehilangan informasi spasialnya yang akan diekstraksi fitur dan diklasifikasikan. Hal ini akan menambah tingkat akurasi dan optimum algoritma CNN. Seperti pada kubus yang memiliki skala pada panjang, lebar, dan tinggi. Jika hanya menggunakan *Neural Network* biasa, mungkin hanya memuat skala panjang dan tinggi.

Namun CNN bisa memuat semua informasi dari keseluruhan skala yang bisa mengklasifikasikan objek dengan lebih akurat karena bisa menggunakan skala lebarnya juga (yang mungkin tidak akan terlihat oleh Neural Network lainnya yang berdimensi dua). Dengan CNN diharapkan pengklasifikasian objek pada penelitian ini dapat menghasilkan hasil yang lebih akurat.

2.4 Face Recognition


Pengenalan wajah adalah salah satu ilmu yang terdapat di dalam *computer vision*, di mana sebuah komputer dapat menganalisa suatu citra wajah yang terdapat di dalam sebuah gambar dan dapat menemukan identitas atau data diri dari citra wajah tersebut dengan membandingkan terhadap data-data citra wajah yang sudah disimpan sebelumnya di dalam *database*.



Gambar 2.4 Face Recognition

Umumnya, *face recognition* dilakukan dari sisi depan dengan pencahayaan yang merata ke seluruh wajah. Saragih (Saragih, 2007) mengatakan bahwa *face recognition* adalah satu teknik identifikasi teknologi biometrik dengan menggunakan wajah individu yang bersangkutan sebagai parameter utamanya.

Secara garis besar, proses pengenalan wajah terdiri dari empat proses utama, yaitu deteksi wajah (*face detection*), *alignment* (*face landmarks* dan *face positioning*), ekstraksi ciri atau wajah (*face* atau *feature extraction*), pengenalan wajah (*face recognition*).




Gambar 2.5 Proses Pengenalan Wajah

Face detection merupakan langkah awal untuk melakukan identifikasi wajah atau *face recognition*. Pendeteksi wajah yang ideal seharusnya mampu untuk mengidentifikasi dan menemukan lokasi dan luas semua wajah yang ada di dalam sebuah gambar tanpa memperhatikan pose, skala wajah, orientasi, umur seseorang, dan ekspresi (Li dan Jain, 2005). *Face detection* mempunyai beragam algoritma yang dapat diterapkan dengan tujuan untuk memberikan kecepatan dan akurasi dalam mendeteksi wajah seperti *Haar Cascade Face Detector*, *HOG Face Detector*, dan *Convolutional Neural Network (CNN) Cascade*. Setelah wajah di deteksi, proses selanjutnya adalah *face alignment*. *Face alignment* bertujuan untuk mendapatkan akurasi yang lebih baik dan tinggi untuk lokalisasi dan normalisasi citra wajah, karena deteksi wajah menyediakan batas lokasi dan skala dari setiap citra wajah yang dapat terdeteksi. Setelah wajah dilakukan normalisasi, dilakukanlah *face extraction* yang digunakan untuk mengambil data yang efektif dan berguna untuk memisahkan antara citra-citra wajah dan orang-orang yang berbeda satu sama lain.

Tahap terakhir adalah *face recognition* atau pencocokan wajah. Proses ini dilakukan dengan cara melakukan pencocokan fitur yang telah diekstraksi dengan citra wajah yang telah tersimpan sebagai *database* wajah.

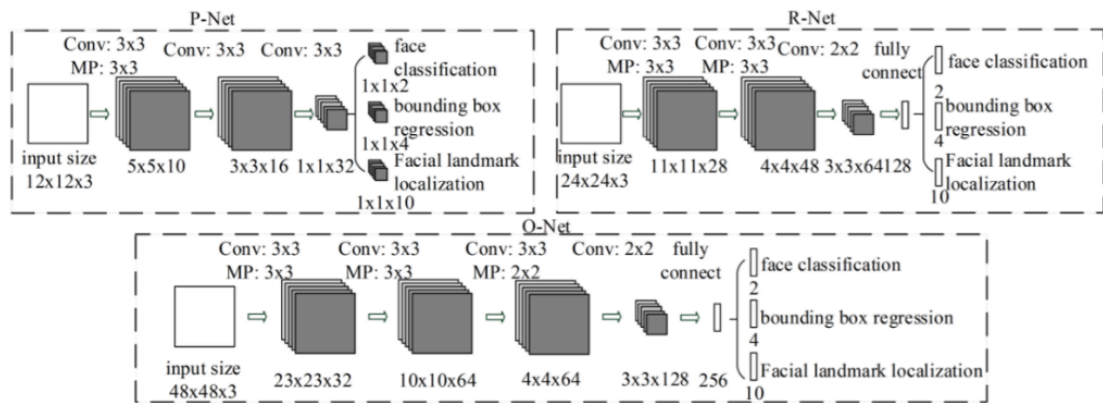
2.5 Multi-task Cascaded Convolutional Neural Network (MTCNN)

Metode konvensional seperti Haar *cascade* dan HOG berfokus pada menemukan descriptor fitur terbaik untuk menggambarkan pola visual wajah secara langsung. Namun, perkembangan *deep learning* belakangan ini mendorong upaya lebih jauh dengan memaksakan mesin untuk mempelajari pola secara otomatis. Pembelajaran pola secara otomatis ini dapat dicapai dengan penggunaan *deep learning*, khususnya menggunakan *convolutional neural network*. Konvolusi merupakan integral yang mengukur seberapa banyak dua fungsi saling tindih ketika satu fungsi melewati fungsi lainnya, atau menganggap bahwa konvolusi merupakan cara menggabungkan dua fungsi dengan mengalikannya. Dalam *convolutional neural network*, filter yang dilalui cukup banyak melalui satu tambalan gambar. Setiap filter akan mengambil pola yang berbeda dan menghasilkan peta fitur. Semakin dalam lapisan CNN yang berjalan, pola yang lebih kompleks (peta fitur) akan diambil. Peta fitur (*feature map*) ini akan menjadi deskriptor fitur yang dapat digunakan untuk mengklasifikasikan apakah gambar merupakan wajah atau tidak.



Gambar 2.6 Peta Fitur dari *Convolutional Neural Network*

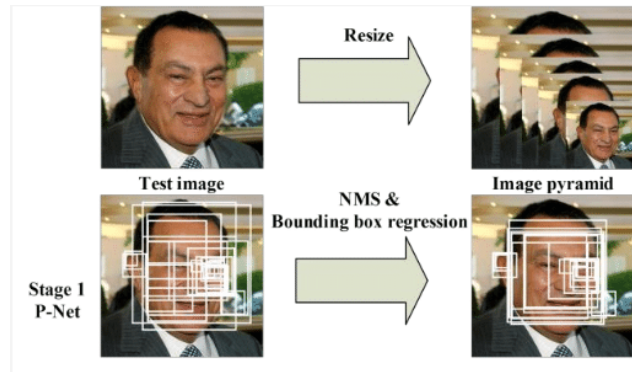
Multi-task cascade convolutional neural network (MTCNN) merupakan *framework* yang diterapkan oleh Kaipeng Zhang (Zhang, et al, 2016) yang mana dalam *framework* ini dilakukan penggabungan *face detection* dan *face alignment*.



Gambar 2.7 Arsitektur MTCNN

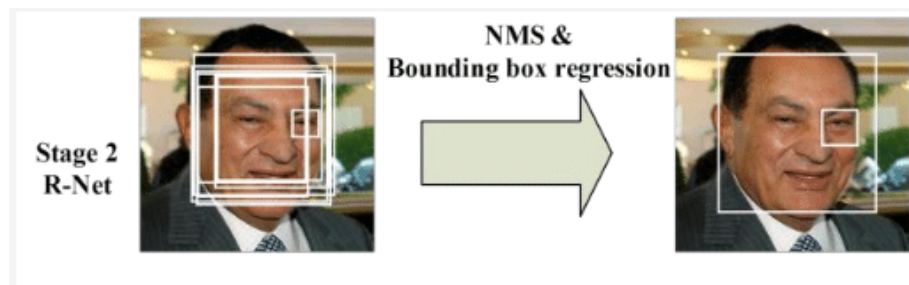
Multi-task cascade convolutional neural network (MTCNN) ini mengusulkan 3 tahapan untuk melakukan penggabungan tersebut. 3 tahapan tersebut adalah :

- Tahapan pertama, *fully convolutional network* yang disebut dengan Proposal Network (P-Net) digunakan untuk mendapatkan daerah yang diusulkan dan vektor regresi dari *bounding box*. Vektor regresi yang diperoleh digunakan untuk mengkalibrasi daerah yang diusulkan dan kemudian menerapkan *non-maxima suppression* (NMS) untuk menggabungkan daerah yang sangat tumpang tindih (*overlapping*)




Gambar 2.8 Tahapan P-Net pada MTCNN

- b. Setelah mendapatkan hasil dari p-net, maka akan diumpunkan ke CNN lain yang disebut dengan *Refine Network* (R-Net). *Refine Network* (R-Net) ini akan menolak kandidat-kandidat palsu, melakukan kalibrasi lain dengan regresi *bounding box* dan juga melakukan penggabungan kandidat NMS



Gambar 2.9 Tahapan R-Net pada MTCNN

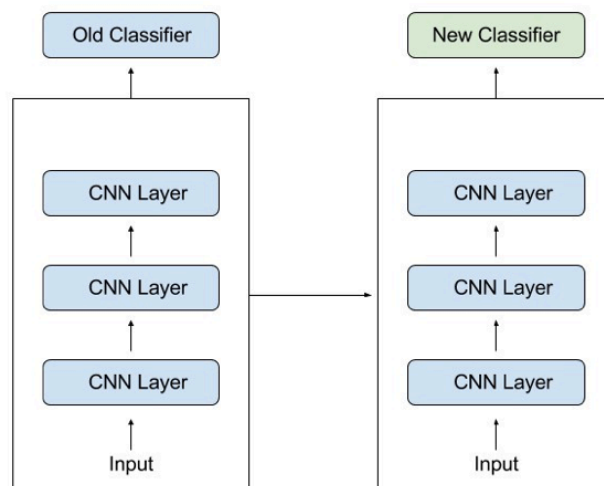
- c. Tahapan ketiga, mirip seperti tahapan yang kedua dan dinamakan dengan *Output Network* (O-Net). Tahapan ini memberikan deskripsi wajah secara detail, dan juga memberikan hasil 5 tanda posisi wajah



Gambar 2.10 Tahapan O-Net pada MTCNN

2.6 Transfer Learning


Transfer Learning adalah metode yang populer dalam *computer vision* yang memungkinkan untuk membangun model yang akurat dengan cara yang lebih efisien (Rawat dan Wang, 2017). Dengan *transfer learning*, proses pembelajaran tidak dimulai dari awal, tetapi mulai dari pola yang telah dipelajari saat memecahkan masalah yang berbeda. Hal ini dapat memanfaatkan pembelajaran sebelumnya dan menghindari memulai dari awal. Penggunaan *transfer learning* ini berguna ketika model yang telah dilatih sebelumnya mempunyai hambatan seperti pencahayaan yang terlalu terang pada wajah.



Gambar 2.11 Alur Proses *Transfer Learning*

2.6.1 Triplet Loss

Triplet loss merupakan sebuah algoritma yang diterapkan dalam *OpenFace* sebagai salah satu komponen dari proses *stochastic gradient descent* pada saat training (Amos et al., 2016). Ilustrasi mengenai mekanisme dari *Triplet Loss* dapat dilihat pada Gambar 2.12.

Gambar 2.12 *Triplet Loss*

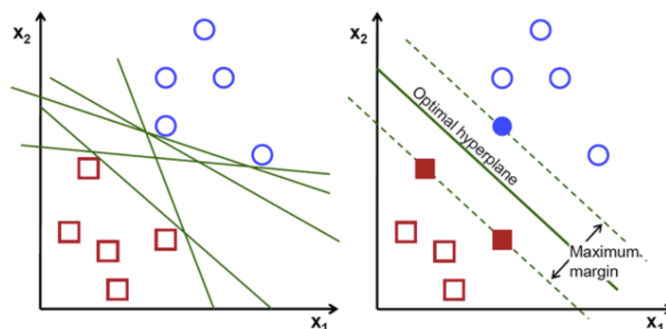
Triplet Loss memiliki input berupa triplet yang terdiri atas *anchor*, *positive*, dan *negative*. Dalam bentuk notasi, input ini dapat ditulis sebagai $\{X_a, X_p, X_n\}$ dimana X_a merupakan *anchor*, X_p merupakan *positive*, dan X_n merupakan *negative*. *Triplet Loss* bertujuan agar jarak antara *anchor* dengan *positive images* menjadi lebih dekat daripada dengan *negative images* (Schroff et al., 2015). Secara formal, definisi dari *Triplet Loss* dapat dilihat pada Formula (2.1):

$$\|f(x_i^a) - f(x_i^p)\|_2^2 + \alpha < \|f(x_i^a) - f(x_i^n)\|_2^2 \quad (2.1)$$

Pada notasi tersebut dapat dilihat adanya *parameter* α . *Parameter* ini dikenal sebagai *margin* yang pada penerapannya bernilai 0.2. Hal ini bertujuan agar selisih antara *anchor-positive pair* dengan *anchor-negative pair* bernilai relatif jauh, dimana hal ini pada umumnya akan memberikan performa yang baik dalam proses *training*. Sebaliknya, *triplet pairs* yang memiliki nilai diluar *margin* tersebut akan diabaikan karena memiliki resiko yang dapat menyebabkan proses *training* menjadi gagal (*collapsed*) dengan terjadinya *early convergence*. Dengan demikian, dapat disimpulkan bahwa dalam *Triplet Loss* tidak semua *triplet pairs* yang tersedia dapat digunakan.

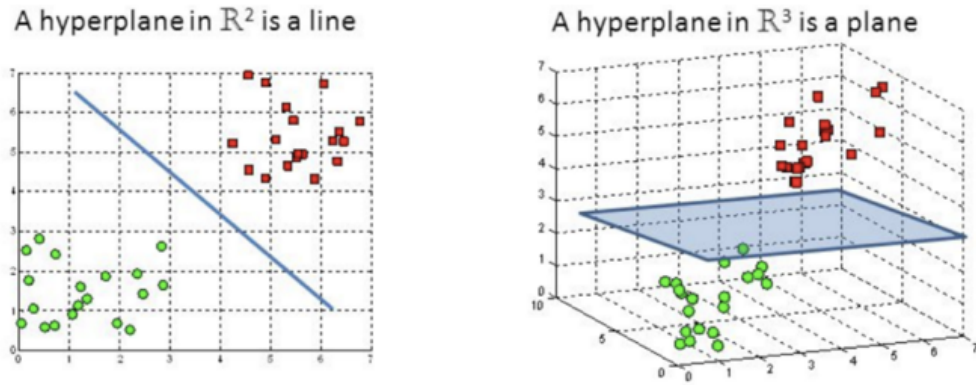
2.7 Support Vector Machine (SVM) Classifier

Support Vector Machine (SVM) merupakan metode *machine learning* yang bekerja atas prinsip *Structural Risk Minimization* (SRM) dengan tujuan menemukan *hyperplane* yang memisahkan dua buah *class* pada input *space* (Byun, et al, 2003).



Gambar 2.13 Hyperplane pada SVM

Untuk memisahkan dua kelas dari titik data, ada banyak kemungkinan *hyperplanes* yang dapat dipilih. Tujuannya adalah untuk menemukan *plane* yang mempunyai maximum margin, contoh: jarak maksimum antara titik data pada setiap kelas. Memaksimalkan jarak margin memberikan penguatan sehingga titik data selanjutnya dapat diklasifikasikan dengan lebih akurat. *Hyperplanes* adalah batas keputusan yang membantu untuk mengklasifikasikan titik data. titik data yang jatuh di kedua sisi *hyperplane* dapat dikaitkan dengan kelas yang berbeda dan juga dimensi *hyperplane* tergantung pada jumlah fitur. Jika jumlah fitur input adalah 2, maka *hyperplane* hanyalah sebuah garis. Jika jumlah fitur input adalah 3, maka *hyperplane* menjadi bidang dua dimensi.



Gambar 2.14 *Hyperplane* pada 2D dan 3D

Untuk mendapatkan *hyperplane* yang terbaik, maka dapat ditemukan dengan menggunakan rumus berikut :

$$\max L_D = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1, j=1}^n \alpha_i \alpha_j y_i y_j x_i x_j \quad (2.2)$$

Dengan $\{X_1, \dots, X_n\}$ adalah *dataset* input, dan $y_i \in \{+1, -1\}$ adalah label kelas dari data X_i . Dengan hasil tersebut akan terdapat nilai untuk setiap data *training*. Data *training* yang memiliki nilai $\alpha_i > 1$ adalah *support vector* sedangkan sisanya memiliki nilai $\alpha_i = 0$. Menurut Campbell, *support vectors* adalah titik data yang lebih dekat ke *hyperplane* dan mempengaruhi posisi dan orientasi *hyperplane* (C, Campbell, 2011). Dengan menggunakan vector-vektor pendukung ini, margin *classifier* dapat dimaksimalkan untuk memberikan hasil klasifikasi yang akurat. Dalam memaksimalkan fungsi margin, maka nilai *output* diambil dari fungsi linear dan jika *output* lebih besar dari 1 ditambahkan satu kelas, tetapi jika *output* -1 maka diklasifikasikan dengan kelas yang lain.

2.8 Raspberry Pi

Raspberry Pi adalah sebuah komputer papan tunggal (*single-board computer*) atau SBC berukuran kartu kredit. *Raspberry Pi* telah dilengkapi dengan semua fungsi layaknya sebuah komputer lengkap, menggunakan SoC (*System-on-a-chip*) ARM yang dikemas dan diintegrasikan diatas PCB. Perangkat ini menggunakan kartu SD untuk *booting* dan penyimpanan jangka panjang. (Bambang Yuwono, dkk. 2015). *Raspberry Pi* memiliki dua model yaitu model A dan model B. Secara umum *Raspberry Pi* Model B, 512MB RAM. Perbedaan model A dan B terletak pada memory yang digunakan, Model A menggunakan memory 256 MB dan model B 512 MB. Selain itu model B juga sudah dilengkapi dengan ethernet port (kartu jaringan) yang tidak terdapat di model A. Desain *Raspberry Pi* didasarkan seputar SoC (System-on-a-chip) Broadcom BCM2835, yang telah menanamkan prosesor ARM1176JZF-S dengan 700 MHz, VideoCore IV GPU, dan 256 Megabyte RAM (model B). Penyimpanan data didisain tidak untuk menggunakan hard disk atau solid-state drive, melainkan mengandalkan kartu SD (SD memory card) untuk booting dan penyimpanan jangka panjang. Hardware *Raspberry Pi* tidak memiliki real-time clock, sehingga OS harus memanfaatkan timer jaringan server sebagai pengganti. Namun komputer yang mudah dikembangkan ini dapat ditambahkan dengan fungsi *real-time* (seperti DS1307) dan banyak lainnya, melalui saluran GPIO (*General-purpose input/output*) via antarmuka I2C (*Inter- Integrated Circuit*). *Raspberry Pi* bersifat open source (berbasis Linux), *Raspberry Pi* bisa dimodifikasi sesuai kebutuhan penggunanya. Sistem operasi utama *Raspberry Pi* menggunakan Debian GNU/Linux dan bahasa pemrograman *Python*.

2.8.1 *Rapsberry Pi 3*

Raspberry Pi 3 merupakan generasi ketiga dari keluarga *Raspberry Pi*. *Raspberry Pi 3* memiliki RAM 1GB dan grafis *Broadcom VideoCore IV* pada frekuensi *clock* yang lebih tinggi dari sebelumnya yang berjalan pada 250MHz. *Raspberry Pi 3* menggantikan *Raspberry Pi 2* model B pada bulan Februari 2016. Kelebihannya dibandingkan dengan *Raspberry Pi 2* adalah:

- A 1.2GHz 64-bit *quad-core* ARMv8 CPU
- 802.11n *Wireless* LAN
- *Bluetooth* 4.1
- *Bluetooth Low Energy* (BLE)

Sama seperti *Pi 2*, *Raspberry Pi 3* juga memiliki 4 USB port, 40 pin GPIO, *Full* HDMI port, Port Ethernet, *Combined* 3.5mm audio jack and composite video, *Camera interface* (CSI), *Display interface* (DSI), slot kartu *Micro SD* (Sistem tekan-tarik, berbeda dari yang sebelum nya ditekan-tekan), dan *VideoCore IV* 3D *graphics core*.



Gambar 2.15 *Rapsberry Pi 3*

2.9 Tinjauan Pustaka

Beberapa penelitian sudah dilakukan untuk memberikan tingkat akurasi yang tinggi dalam mendeteksi wajah pada kasus yang berbeda-beda. Rangkuman tinjauan pustaka mengenai penelitian yang telah dilakukan pada kasus *face recognition* dapat dilihat pada tabel 2.1 berikut ini.

Tabel 2.1 Ringkasan Tinjauan Pustaka

Sumber	Faktor/Variabel Penelitian	Metode	Kekurangan	Akurasi
(Hitoshi et al., 2009)	<i>Multiple faces</i> dan <i>hand recognition</i>	Memakai <i>multiple camera</i> yang terdiri dari 2 <i>tracking cam</i> dan 2 <i>stereo cam</i> (Hitoshi, 2009). <i>Stereo camera</i> berfungsi untuk mendeteksi wajah dan mengukur jarak masing-masing dari <i>stereo camera</i> yang kemudian akan diolah menggunakan <i>quardplet image switcher</i> , sedangkan <i>tracking camera</i> berfungsi untuk melakukan <i>zooming</i> dan <i>tilt angles</i> pada wajah.	Akurasi sangat baik tetapi nilai akurasi menurun ketika adanya <i>overlapping people</i>	96%

(Li et al., 2015)	Mendeteksi wajah pada kondisi tidak terkontrol (<i>pose</i> , cahaya, dan ekspresi)	Mengkombinasikan <i>multiple-resolution</i> pada kondisi tidak terkontrol saat mendeteksi wajah dengan menggunakan CNN <i>cascade</i>	Membutuhkan kalibrasi <i>bounding box</i> dari deteksi wajah dengan biaya komputasi extra dan mengabaikan kolerasi yang melekat antara lokalisasi <i>face landmark</i> dan regresi <i>bounding box</i>	94.2%
(Zhang et al., 2015)	Mendeteksi <i>multiple faces</i> dan ekspresi, hingga kondisi <i>overlapping</i>	Mengintegrasikan <i>face detection</i> dan <i>face alignment</i> menggunakan CNN <i>cascade</i> dengan <i>multi-task learning</i> .	Memberikan total 6.9 mean error pada lokalisasi <i>left eye</i> , <i>right eye</i> , <i>nose</i> , <i>left mouth corner</i> , and <i>right mouth corner</i> .	95,1%
(Marko et al., 2017)	Menggunakan <i>deep learning</i> berbasis <i>face recognition</i> untuk absensi	Menggunakan CNN <i>cascade</i> sebagai <i>face detector</i> , menggunakan <i>facenet</i> untuk <i>face embeddings</i> , dan menggunakan SVM <i>classifier</i> untuk mengklasifikasikan wajah	Tidak diuji cobakan pada banyak wajah, ketika pencahayaan lebih terang, nilai akurasi menurun	95.02%

(Scroff, et al., 2015)	Menggunakan <i>deep neural network</i> untuk melakukan <i>trained FaceNet embeddings</i> , <i>dataset LFW</i>	Melakukan <i>embeddings</i> menggunakan 128d dan menjadi model sekali pakai (<i>one-shot</i>) yang secara langsung mempelajari pemetaan dari gambar wajah ke <i>euclidean space</i> yang ringkas di mana jarak secara langsung berhubungan dengan ukuran kesamaan wajah.	Meningkatkan nilai <i>error</i> pada saat melakukan <i>extra face alignment</i>	99.63%
------------------------	---	--	---	--------

Setelah melakukan tinjauan pustaka dari beberapa penelitian diatas, penulis akan menerapkan metode *Multi-task convolutional neural network* untuk menggabungkan proses *face detection* dan *face alignment*, dan juga untuk mengurangi hambatan pencahayaan yang terlalu terang akan diterapkan metode *trained face embeddings* pada *FaceNet*, serta menggunakan metode *SVM classifier* untuk mengklasifikasikan wajah dan membandingkannya dengan *database* wajah karyawan.

BAB III METODOLOGI

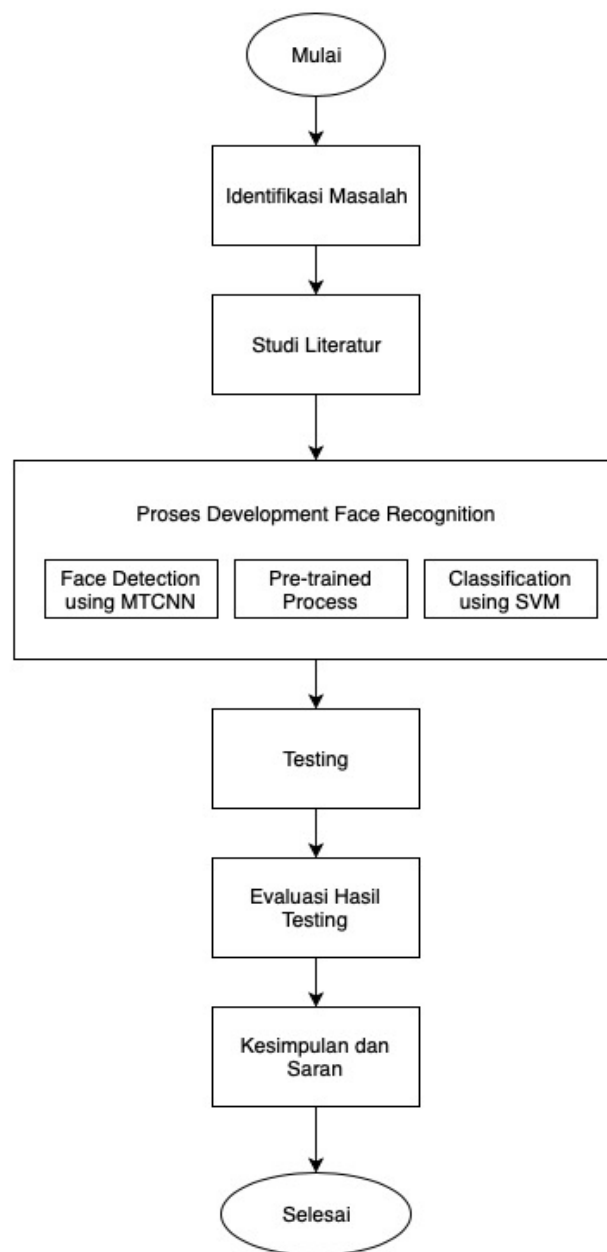
3.1 Kerangka Pikir

Penelitian ini diawali berdasarkan latar belakang dari pentingnya pencatatan absensi karyawan. Pencatatan absensi yang diterapkan semakin canggih seiring dengan berkembangnya teknologi. Namun, terdapat beberapa kendala seperti dapat dilakukan pemalsuan terhadap absensi, adanya antrian saat ingin melakukan absensi di mesin absensi pada jam masuk dan jam pulang, serta sulitnya melakukan pencatatan rata-rata absensi karyawan. Dengan adanya latar belakang dan permasalahan tersebut, penulis menyadari bahwa perlu adanya suatu sistem yang dapat membantu proses ini terutama dalam melakukan pencatatan absensi. Tujuannya adalah pencatatan absensi tidak dilakukan melalui perantara orang dan mesin (contohnya: menggunakan alat absensi berbasis *fingerprint*), dapat mengurangi antrian pada saat melakukan absensi, dan pencatatan rata-rata absensi karyawan dapat lebih mudah dilakukan. Dari perumusan masalah tersebut, penulis ingin menerapkan sistem absensi menggunakan *face recognition*.

Untuk mengimplementasikan sistem absensi menggunakan *face recognition* serta untuk mendukung penyempurnaan fitur-fitur sistem absensi yang digunakan nantinya dan memberikan solusi terhadap hambatan pendeteksian wajah, maka diperlukan analisa kebutuhan terhadap fitur apa yang harus dimiliki oleh sistem absensi, serta melakukan studi literatur untuk mendukung pengembangan dari *face recognition* itu sendiri.

Identifikasi yang direncanakan menggunakan metode *face recognition* tentunya memerlukan penelitian dan pengembangan algoritma agar sesuai dengan kebutuhan dan memiliki tingkat keamanan, serta akurasi sesuai dengan yang dibutuhkan, sehingga proses penelitian dan *development* algoritma *face recognition* harus dilakukan dalam penelitian ini. *Development* pada *face recognition* itu sendiri mempunyai 3 tahapan, tahapan pertama adalah mendeteksi wajah menggunakan metode *Multi-task Convolutuional Neural Network*, kemudian dilakukan proses *embeddings* dengan melakukan *pre-trained* CNN pada *FaceNet*, dan langkah terakhir adalah melakukan *classifier* menggunakan metode linear *Support Vector Machine* (SVM).

Untuk menjelaskan permasalahan yang ada, maka dirasa perlu untuk menggunakan suatu kerangka pemikiran untuk memudahkan pemahaman alur berpikir dalam penelitian yang dilakukan. Kerangka penelitian dapat dilihat alurnya pada gambar 3.1 berikut ini.




Gambar 3.16 Kerangka Pikir

Dari kerangka pikir yang telah digambarkan diatas, akan dijabarkan lebih detail mengenai proses *development* sistem absensi menggunakan *face recognition* ini pada sub bab perancangan sistem.

3.2 Perancangan Sistem

Sistem absensi yang akan dibangun menggunakan satu buah sensor kamera *Raspberry Pi V2* yang kemudian akan dihubungkan ke *Raspberry Pi 3 B+* yang selanjutnya akan di koneksikan pada komputer untuk memproses hasil wajah tersebut dan memasukkannya sebagai data absensi. Ilustrasinya akan digambarkan sebagai berikut :

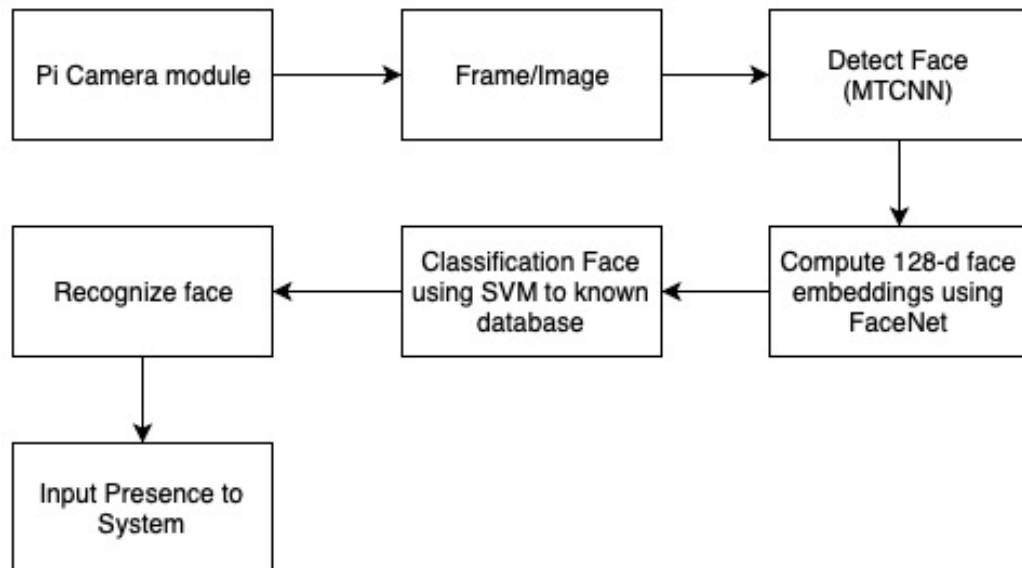


Gambar 3.2 Ilustrasi Sistem

Cara kerjanya sistem absensi tersebut adalah sebagai berikut :

1. Wajah karyawan difoto dan dimasukkan ke dalam *database* wajah karyawan
2. Karyawan datang melalui pintu yang telah dipasang sensor kamera, kemudian sensor akan menangkap wajah, dan akan diproses melalui sistem untuk mencatat absen

Kemudian proses *face detection* hingga *face classification* akan dilakukan menggunakan *library* pada *tensorflow* yang merupakan *computational framework* pada *machine learning*.



Gambar 3.3 Perancangan Sistem Face Recognition

Metode pendeteksian wajah ini menggunakan model *Multi-task Convolutional Neural Network* yang memiliki 3 *network* yang berbeda. Setiap wajah yang ditangkap, *network* tersebut membentuk *image pyramid* yang menyalin gambar wajah menjadi beberapa ukuran.

Cara melatih model *Multi-task Convolutional Neural Network* tersebut dapat dilakukan dengan cara sebagai berikut:

1. Pada P-Net, untuk setiap gambar berskala, kernel 12x12 menelusuri gambar, dan mencari wajah. Bentuknya seperti kotak yang perlahan-lahan bergerak melintasi gambar dan mencari wajah. Maka model akan memangkas setiap gambar sebelum proses *training* (menjadi 12x12 piksel untuk P-Net, 24x24 piksel untuk R-Net, dan 48x48 piksel untuk O-Net)

Kemudian gambar tersebut diklasifikasikan sebagai positif atau negatif berdasarkan IoU (titik temu Union, yaitu memotong area antara gambar 12x12 dan kotak pembatas dibagi dengan total area gambar 12x12 dan *bounding box*), dan termasuk kategori terpisah untuk “bagian” wajah. Membuat kategori “bagian” wajah yang terpisah ini memungkinkan *network* mempelajari wajah yang sebagian tertutup. Dengan cara ini, bahkan memungkinkan jika setengah wajah berpaling, *network* masih dapat mengenali wajah.

2. Selain itu, untuk pelatihan R-Net dan O-Net akan digunakan *hard sample mining* yang berfungsi untuk mengurangi *false part* dan *negative sample*. Bahkan setelah training, P-Net tidak sempurna, model ini masih akan mengenali beberapa gambar tanpa wajah di dalamnya sebagai gambar positif (dengan wajah). Gambar-gambar ini dikenal sebagai *false positive*. Karena pekerjaan R-Net adalah untuk memperbaiki tepi kotak yang terikat dan mengurangi *false positive*, setelah melatih P-Net maka nilai *false positive* P-Net akan tetap diambil dan memasukkannya ke dalam R-Net *training*. Percobaan ini dapat membantu R-Net menargetkan kelemahan dari P-Net dan meningkatkan akurasi. Proses ini dikenal sebagai *hard simple mining*. Demikian pula, *hard simple mining* juga akan dilakukan pada O-Net *training*.

Selanjutnya, pada tahapan *face embeddings* menggunakan *FaceNet* akan dilakukan *training* pada *triplet loss*. *Triplet loss function* ini mengambil *face encoding* dari 3 gambar *anchor*, *positive*, dan *negative*.

Kemudian *generate anchor*, *positive*, dan *negative* menggunakan *generator code* yang akan men-*generate triplets* secara acak. Lalu *training* pada *FaceNet* dapat dilakukan.

Pada *softmax multiclass SVM classifier*, terdapat permasalahan yang disebut dengan pendekatan *one-vs-rest*. Permasalahan ini dapat diselesaikan dengan melatih K *linear* secara terpisah, yang mana data didapatkan dari kelas lain yang berisi *negative case*. Yang mana denotasi hasil output dari k -th SVM adalah :

$$\alpha_k(x) = w^T \quad (3.1)$$

Prediksi kelasnya adalah :

$$\arg \max_k \alpha_k(X) \quad (3.2)$$

Prediksi menggunakan SVM hampir sama dengan penerapan *softmax*. Namun, pada *softmax* parameter nya dihitung menggunakan *weight matrices* (w). *softmax* layer dapat meminimalisir *cross-entropy* (perbedaan antara dua distribusi probabilitas) atau memaksimalkan *log-likelihood* (meng-estimasi parameter).

3.3 Pengambilan Data

Pada penelitian ini akan dilakukan pengambilan data untuk pengujian sistem absensi, dapat dilihat pada tabel 3.1 berikut ini :

Tabel 3.1 Pengambilan Data

Jumlah Karyawan	Jumlah Pengujian	Jenis Kelamin	Kondisi Pencahayaan	Aksesoris Wajah
1	5 kali	Wanita	Normal	Tidak ada
1	5 kali	Pria	Normal	Berkacamata
2-5	10 kali	Wanita	Normal	1 karyawan menggunakan topi, 2 karyawan kondisi normal, 2 karyawan berkacamata
2-5	10 kali	Pria	Normal	1 karyawan menggunakan masker, 2 karyawan kondisi normal, 2 karyawan berkacamata
2-5	10 kali	Pria dan wanita	Normal	1 karyawan menggunakan masker, 2 karyawan kondisi normal, 2 karyawan berkacamata
1	5 kali	Wanita	Agak gelap (beberapa lampu disekitar sensor sudah redup)	Menggunakan <i>softlens</i>
1	5 kali	Pria	Agak gelap	Tidak ada

2-5	10 kali	Wanita	Agak gelap	1 karyawan berkacamata, 4 lainnya normal
2-5	10 kali	Pria	Agak gelap	1 karyawan menggunakan masker, 2 karyawan kondisi normal, 2 karyawan berkacamata
2-5	10 kali	Pria dan wanita	Agak gelap	1 karyawan menggunakan masker, 2 karyawan kondisi normal, 2 karyawan berkacamata
1	5 kali	Wanita	Terang (kondisi pintu terbuka sehingga cahaya matahari masuk)	Menggunakan kacamata
1	5 kali	Pria	Terang	Tidak ada
2-5	10 kali	Wanita	Terang	1 karyawan berkacamata, 4 lainnya normal
2-5	10 kali	Pria	Terang	1 menggunakan masker, 2 karyawan kondisi normal, 2 karyawan berkacamata
2-5	10 kali	Pria dan wanita	Terang	1 menggunakan masker, 2 kondisi normal, 2 karyawan berkacamata

Dari hasil pengambilan data yang telah dilakukan, selanjutnya data yang telah di dapatkan akan dianalisa untuk melihat apakah metode yang penulis terapkan sudah memberikan akurasi dan kecepatan dalam pencatatan absensi menggunakan *face recognition*.

3.4 Analisis Data

Hasil dari uji coba sistem akan menghasilkan sejumlah data yang kemudian dapat dianalisis terkait keberhasilan dan keakuratan data tersebut sehingga hasil yang diinginkan dapat dikatakan sudah tercapai. Adapun skenario analisis data yang akan dilakukan pada sistem absensi adalah sebagai berikut :

1. Dari hasil pengambilan data, dilakukan pengecekan apakah model yang diusulkan dapat berjalan dengan baik atau tidak, dan juga dilakukan pengecekan apakah pendeteksi wajah telah memberikan hasil yang akurat terhadap *database* karyawan atau tidak
2. Tahap kedua adalah melakukan pengecekan terhadap tingkat akurasi pada kondisi pencahayaan agak gelap. Jika ternyata akurasi pada kondisi pencahayaan agak gelap dirasa masih memberikan nilai akurasi yang rendah, maka penulis akan melakukan proses untuk meningkatkan *brightness* pada wajah terlebih dahulu, kemudian di uji cobakan kembali
3. Tahap ketiga adalah melakukan pengecekan terhadap tingkat akurasi pada kondisi pencahayaan terang. Jika ternyata akurasi pada kondisi pencahayaan terang dirasa masih memberikan nilai akurasi yang rendah, maka penulis akan melakukan proses untuk menurunkan *brightness* pada wajah terlebih dahulu, kemudian di uji cobakan kembali

1. Tahap keempat adalah melakukan pengecekan terhadap benar atau tidaknya pendeteksian wajah pada wajah yang menggunakan aksesoris (kacamata, masker). Jika hasil yang di proses sudah benar, maka akan dicek tingkat akurasi. Namun jika hasil identifikasi wajah masih salah, maka penulis akan melakukan proses penghapusan aksesoris pada wajah dengan *library* yang ada pada *python*, kemudian di uji cobakan kembali
2. Tahap terakhir adalah melakukan pengecekan apakah jenis kelamin mempengaruhi hasil dari pendeteksian wajah. Jika hal tersebut mempengaruhi tingkat akurasi, maka penulis akan melakukan proses klasifikasi terlebih dahulu pada jenis kelamin, kemudian di uji cobakan kembali

3.5 Jadwal Penelitian

Jadwal pengerjaan penelitian sesuai dengan alur penelitian pada gambar 3.1 diatas dapat dilihat pada tabel 3.2 berikut ini.

Tabel 3.2 Jadwal Penelitian

[illegible]

DAFTAR PUSTAKA

- Alahi, and okayGoel, et al. (2016). Social LSTM: Human Trajectory Prediction in Crowded Space. *IEEE convention on computer vision and pattern recognition, 113(2)*, 961-971.
- Byun H., Lee S.W. (2013). A Survey on Pattern Recognition Applications of Support Vector Machines. *International Journal of Pattern Recognition and Artificial Intelligence*, Vol.17, No.3, pp.459-486.
- Campbell, C dan Ying, Y. (2011). *Learning with Support Vector Machines, Buku seri Synthesis Lectures on Artificial Intelligence and Machine Learning*, Morgan & Claypool Publisher, UK.
- H. Li, Z. Lin, X. Shen, J. Brandt, and G. Hua. (2015). A convolutional neural network cascade for face detection. *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 5325-5334.
- Hitoshi Hongo, Mitsunori Ohya, et al. (2009). Focus of attention for face and hand gesture recognition using multiple cameras. *IEEE International Conference on Automatic Face and Gesture Recognition*.
- J.D. Woodward., et al. (2001). *Army Biometric Applications: Identifying and Addressing Sociocultural Concerns. RAND*.
- J.L. Wayman and L. Alyea. (2001). Picking the Best Biometric for Your Applications, in National Biometric Test Center Collected Works. *National Biometric Test Center: San Jose. p. 269-275*.

- Kadry, Seifedine, and Mohamad Smaili. (2013). Wireless attendance management system based on iris recognition. *Scientific Research and Essays* 5.12 1428-1435.
- Lang Liying, and Hong Yue. (2008). The Study of Entrance Guard & Check on Work Attendance System Based on Face Recognition. *International Conference on Computer Science and Information Technology*.
- Markov Arsenovic, Srdjan Sladojevic, Andras Anderla, Darko Stefanovic. (2017). FaceTime – Deep Learning Based Face Recognition Attendance System. *IEEE International Symposium on Intelligent Systems and Informatics*.
- P. Viola and M. Jones. (2001). Robust Real-time Object Detection. *vol. 57, no. 2, pp. 1–25*.
- Rao, Seema, and K. J. Satoa.(2013). An Attendance Monitoring System Using Biometrics Authentication. *International Journal of Advanced Research in Computer Science and Software Engineering Volume 3, Issue 4*.
- Saragih, Riko Arlando. (2017). Pengenalan Wajah Menggunakan Metode Fisher Face. *Fakultas Teknologi Industri – Universitas Kristen Petra, 50-62*.
- Schroff, Florian, Dmitry Kalenichenko, and James Philbin. (2015). Facenet: A unified embedding for face recognition and clustering. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*.
- V. Badarinarayan, et al. (2015). SegNet: A Deep Convolutional Encoder- Decoder Architecture for Robust Semantic Pixel-Wise Labelling. *In arXiv preprint arXiv (Vol. Vol 1)*.

- Yuwono, Bambang. (2015). Pengembangan Model Public Monitoring System Menggunakan Raspberry Pi Diambil dari :
<http://jurnal.upnyk.ac.id/index.php/telematika/article/viewFile/1409/1291> (1 Mei 2018)
- Z. Zhang, P. Luo, C. C. Loy, and X. Tang. (2014). Facial landmark detection by deep multi-task learning. *European Conference on Computer Vision*, pp. 94-108.